

Министерство образования и науки Российской Федерации
федеральное государственное автономное образовательное учреждение высшего образования
**“САНКТ-ПЕТЕРБУРГСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ,
МЕХАНИКИ И ОПТИКИ”**

**ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ**

**МОДЕЛЬ АВТОМАТИЧЕСКОГО ПОИСКА И
КЛАССИФИКАЦИИ ГЕМАТОМ НА ИССЛЕДОВАНИЯХ
КОМПЬЮТЕРНОЙ ТОМОГРАФИИ**

Автор Татарский Владимир Андреевич _____
(Фамилия, Имя, Отчество) _____ (Подпись)
Направление подготовки 09.04.01
(специальность) «Информатика и вычислительная техника»
Квалификация магистр _____
(бакалавр, инженер, магистр)

Руководитель Радченко И.А., доцент, к.т.н. _____
(Фамилия, И., О., ученое звание, степень) _____ (Подпись)

К защите допустить

Зав. кафедрой Муромцев Д.И., доцент, к.т.н. _____
(Фамилия, И., О., ученое звание, степень) _____ (Подпись)

«____ » _____ 20 ____ г.

Санкт-Петербург, 2018 г.

Студент Татарский В. А. Группа B4215 Кафедра ИПМ Факультет ПИиКТ
(ФИО)

Направленность (профиль),
специализация «Математические модели и компьютерное моделирование»

ВКР принята “ ____ “ 20 ____ г.

Оригинальность ВКР _____ %

ВКР выполнена с оценкой _____

Дата защиты “ ____ “ 20 ____ г.

Секретарь ГЭК _____ ФИО _____ Подпись

Листов хранения _____

Демонстрационных материалов / Чертежей хранения _____

Министерство образования и науки Российской Федерации

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ**

**“САНКТ-ПЕТЕРБУРГСКИЙ НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ,
МЕХАНИКИ И ОПТИКИ”**

УТВЕРЖДАЮ

Зав. кафедрой _____

_____ (ФИО) _____ (подпись)
« » « » 20 Г.

ЗАДАНИЕ

НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ РАБОТУ

Студенту Татарскому В.А. Группа Р4215 Кафедра ИПМ Факультет ПИиКТ

Руководитель Университет ИТМО, к.т.н., доцент, Радченко Ирина Алексеевна

(ФИО, ученое звание, степень, место работы, должность)

1 Наименование темы: «Модель автоматического поиска и классификации гематом на исследованиях компьютерной томографии»

Направление подготовки (специальность) 09.04.01 Информатика и вычислительная техника

Направленность (профиль) 09.04.01 Математические модели и компьютерное моделирование

Квалификация Магистр

3 Срок сдачи аспирантам законченной работы: «...» «...» 20... г.

3. The following table summarizes the results of the experiments.

Требуется реализовать модели для поиска и классификации гомеопатии.

卷一

исследованиях компьютерной томографии. В рамках выпускной квалификационной работы необходимо:

- исследований в формате DICOM

 2. изучить теоретические основы построения систем с применением нейронных сетей
 3. провести анализ исходных данных и выполнить их предварительную подготовку
 4. сформировать требования к системе
 5. разработать и реализовать модель поиска и классификации
 6. провести анализ полученных результатов

4 Содержание выпускной квалификационной работы (перечень подлежащих разработке вопросов)

1. Описывается характер исходных данных, виды и различия внутримозговых кровоизлияний.
2. Описывается алгоритм поиска гематом по сдвигу средней линии
3. Производится подготовка результатов КТ-исследований для этапа выделения признаков
4. Описывается этап выделения признаков, с применением ряда различных алгоритмов
5. Описывается этап классификации КТ-исследование
6. Приводится анализ полученных результатов

5 Перечень графического материала (с указанием обязательного материала)

Нет

6 Исходные материалы и пособия

1. Richard E Woods, Rafael C «Digital image processing. 3rd edition», 2008
2. Robert Laganiere «OpenCV 3 Computer Vision Application Programming Cookbook - Third Edition», 2017
3. Simon Haykin «NEURAL NETWORKS. A Comprehensive Foundation. Second Edition», 1999
4. Luis Pedro Coelho, Willi Richert «Building Machine Learning Systems with Python. Second Edition», 2015
5. Vikash Ravi Goel, Roy K Greenberg, Donald P Greenberg «Mathematical analysis of DICOM CT datasets: Can endograft sizing be automated for complex anatomy?» Journal of Vascular Surgery, Volume 47, Issue 6, June 2008, Pages 1312

7 Дата выдачи задания « ____ » « _____ » 20 ____ г.

Руководитель ВКР _____
(подпись)

Задание принял к исполнению _____ « ____ » « _____ » 20 ____ г.
(подпись)

Министерство образования и науки Российской Федерации

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ**

**“САНКТ-ПЕТЕРБУРГСКИЙ НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ,
МЕХАНИКИ И ОПТИКИ”**

АННОТАЦИЯ

ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ

Студент Татарский Владимир Андреевич
(ФИО)

Наименование темы ВКР: «Модель автоматического поиска и классификации гематом на исследованиях компьютерной томографии»

Наименование организации, где выполнена ВКР Университет ИТМО

ХАРАКТЕРИСТИКА ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ

1 Цель исследования Разработка и реализация модели поиска и классификации гематом на исследованиях компьютерной томографии

2 Задачи, решаемые в ВКР Сокращение времени и уменьшение количества ошибок при диагностике внутримозговых кровоизлияний

3 Число источников, использованных при составлении обзора 14

4 Полное число источников, использованных в работе 14

5 В том числе источников по годам

Отечественных			Иностранных		
Последние 5 лет	От 5 до 10 лет	Более 10 лет	Последние 5 лет	От 5 до 10 лет	Более 10 лет
			6	2	6

6 Использование информационных ресурсов Internet _____

(Да, нет, число ссылок в списке литературы)

7 Использование современных пакетов компьютерных программ и технологий

(Указать, какие именно, и в каком разделе работы)

Пакеты компьютерных программ и технологий	Параграф работы
Python (pydicom, tensorflow, keras, skimage, matplotlib, numpy, scipy)	3.3-3.7
DICOM	2.3

8 Краткая характеристика полученных результатов

В ходе работы была разработана модель поиска и классификации гематом на исследованиях компьютерной томографии

9 Полученные гранты, при выполнении работы _____
(Название гранта)

10 Наличие публикаций и выступлений на конференциях по теме выпускной работы _____

Да, нет)

а) 1 _____

(Библиографическое описание публикаций)

2 _____

3 _____

б) 1 _____

(Библиографическое описание выступлений на конференциях)

2 _____

3 _____

Студент Татарский В. А. _____
(ФИО) _____
(подпись)

Руководитель Радченко И. А. _____
(ФИО) _____
(подпись)

“ ” 20 г.

Содержание

1.	<i>Введение</i>	8
2.	<i>Теоретическая часть</i>	10
2.1.	Виды внутримозговых кровоизлияний	10
2.2.	Диагностика внутримозговых кровоизлияний	15
2.3.	DICOM.....	17
2.4.	Возможности стандарта DICOM	19
3.	<i>Практическая часть</i>	21
3.1.	Набор данных	21
3.2.	Инструментарий.....	22
3.3.	Поиск.....	23
3.4.	Классификация.....	27
3.5.	Извлечение свойств	39
3.6.	Классификация.....	45
3.7.	Оценка результатов эксперимента.....	60
4.	<i>Заключение</i>	62
5.	<i>Литература</i>	64

1. Введение

Гематома головного мозга чаще всего может быть вызвана внезапной травмой головы и в результате внутреннего кровотечения. Гематомы бывают нескольких видов: эпидуральная (EDH), субдуральная (SDH) и внутримозговая гематомы (ICH). Все эти гематомы являются плотными по своей природе и выглядят ярче в локальных пределах, чем другие ткани головного мозга. Эпидуральная гематома является (EDH) кровотечением между черепом и веществом мышцы головного мозга и имеет двояковыпуклую форму, субдуральная гематома (SDH) – кровотечение, которое находится между твердой и субарахноидальной оболочкой мозга, и имеет серповидную форму. Внутримозговая гематома (ICH) представляет собой сгусток крови внутри мозга, круглой формы, данный тип кровоизлияний очень трудно идентифицировать, поскольку оно напоминает опухоль.

Визуализация является важным инструментом медицинской науки для представления анатомических структур человеческого тела. Медицинский анализ изображений для идентификации и классификации является важной задачей для множества систем диагностики. Существуют различные методы сканирования мозга, которые используются для получения информации радиологом. Компьютерная томография (КТ) является не инвазивным методом, позволяющим получать изображения каждой части тела человека. Сканирование КТ использует рентгеновское излучение, которое обнаруживается рядом датчиков. Информация с датчиков собирается и обрабатывается компьютером и требует большого количества вычислительных мощностей. Результатом КТ-исследования является набор файлов, в каждом из которых содержится один из слоев исследуемой области. КТ-исследование может показать структуру головного мозга, кровеносных сосудов, других тканей и любых аномалий в черепе. КТ-сканирование

является общей системой визуализации в больницах для пациентов с травмой головы и без сознания.

КТ-исследования, по сравнению с технологиями, например такими как МРТ, являются предпочтительными из-за повсеместной доступности, небольшой стоимости, быстрого сканирования и хорошего контраста. С помощью автоматизированной системы можно быстро и точно обнаружить любую патологию в головном мозге.

Целью исследования является разработка не инвазивного диагностического инструмента для автоматического выявления и классификации гематом головного мозга. Система будет полезна для диагностики, и позволит начать лечение как можно раньше.

2. Теоретическая часть

2.1. Виды внутримозговых кровоизлияний

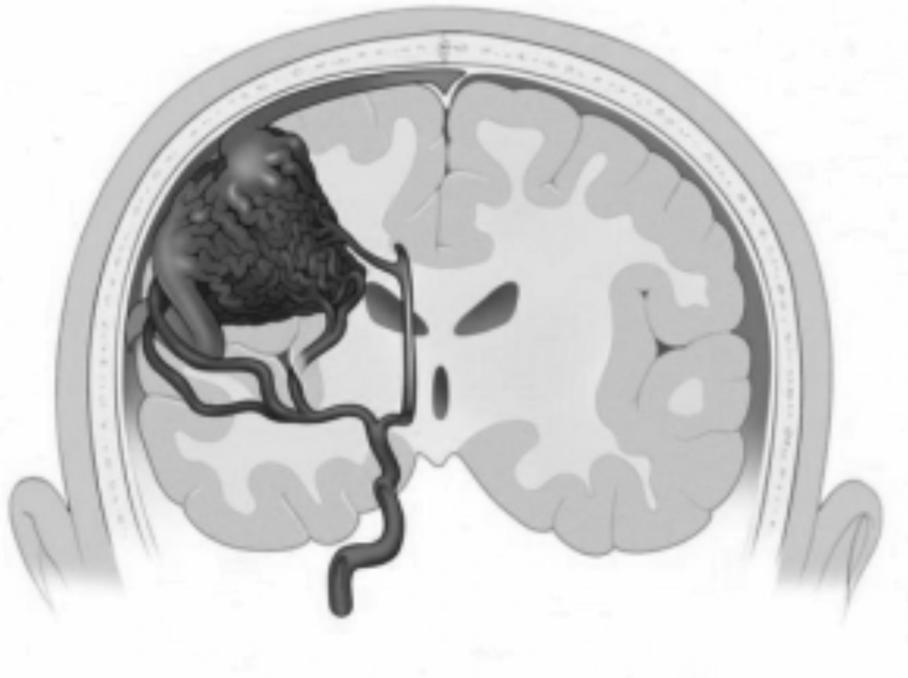


Рис. 1 Схематическое изображение внутримозгового кровоизлияния

Внутримозговое (паренхиматозное) кровоизлияние является острым нарушением мозгового кровообращения (ОНМК) по геморрагическому типу. Оно характеризуется появлением очаговой симптоматики (паралич в руке и ноге, нарушения речи, внезапно развившаяся слепота и т.д.), характер которой зависит от положения и объема кровоизлияния, что сочетается, как правило, с общемозговой симптоматикой (головная боль, тошнота, рвота, внезапное угнетение или потеря сознания), которые сохраняются длительный промежуток времени (более 24 часов).

Клиническая картина кровоизлияния в мозг обусловлена нарушением функций головного мозга сосудистого генеза в результате разрыва патологически измененных артерий мозга, как правило, на фоне высокого АД, наиболее часто при хронической артериальной гипертензии и церебральной

амилоидной ангиопатии. Разрыв сосуда приводит к кровоизлиянию в полость черепа с повреждением паренхимы головного мозга излившейся кровью и продуктами ее распада, отеку головного мозга, сдавлению и смешению внутримозговых структур.

Наиболее точными способами диагностики кровоизлияния в мозг являются КТ или МРТ. При отсутствии возможности проведения методов нейровизуализации, другие способы диагностики являются менее точными и включают в себя анализ клинической картины, данных спинномозговой пункции и эхоэнцефалоскопии.

Патогенетическое лечение внутримозгового кровоизлияния отсутствует. Как правило, проводится комплекс терапевтических мероприятий (базисная терапия) основу которых составляют поддержание оптимального артериального давления и борьба с отеком мозга, а также, возможно, хирургическое лечение, показания к которому до сих пор не устоялись и нет консенсуса относительно эффективности хирургии.

В зависимости от сосредоточения внутримозговые кровоизлияния делятся на следующие группы:

Субдуральное. Наблюдается, когда содержимое собирается под твердой — наиболее плотной — мозговой оболочкой. Зачастую происходит при травмах характера «убыстрение-торможение». В этих случаях на черепно-мозговую коробку воздействуют разнонаправленные силы. Кровоизлияние происходит при разрыве пialльных вен.

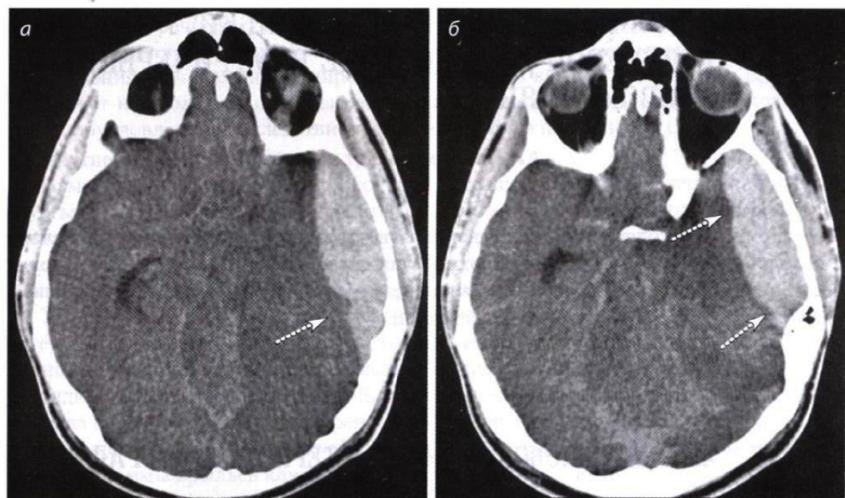


Рис. 2 Иллюстрация субдурального кровоизлияния

Субкортикальное (подкорковое). Кровь локализируется в полушариях головного мозга на стыке затылочной и лобной, височной и теменной долей. Является, как правило, следствием сильно возросшего артериального давления.

Субарахноидальное. Происходит самопроизвольное или под воздействием травмы излитие в подпаутинную — субарахноидальную — зону головного мозга. Среди факторов — провоцирующих нетравматические САК — является аневризма сосудов головного мозга. Чаще она локализуется в области достаточно крупных сосудов — сонных, соединительных и передних мозговых артерий. Ее размер может составлять два и более сантиметров.



Рис. 3 Иллюстрация субарахноидального кровоизлияния

Эпидуральное. Эпидуральная гематома является результатом кровоизлияния в пространство между внутренней поверхностью костей черепа и твердой мозговой оболочкой. ЭГ встречаются как при открытых, так и закрытых ЧМТ, располагаясь обычно на стороне приложения травмы. Обычно развиваются при ударе предметом с небольшой поверхностью по неподвижной или малоподвижной голове, или при ударе головой о неподвижный предмет.



Рис. 4 Иллюстрация эпидурального кровоизлияния

Внутрижелудочковое. В желудочках — пустотах, заполненных спинномозговой жидкостью — головного мозга происходит скопление кровяных сгустков.

Смешанное. Сочетает несколько групп кровоизлияний.

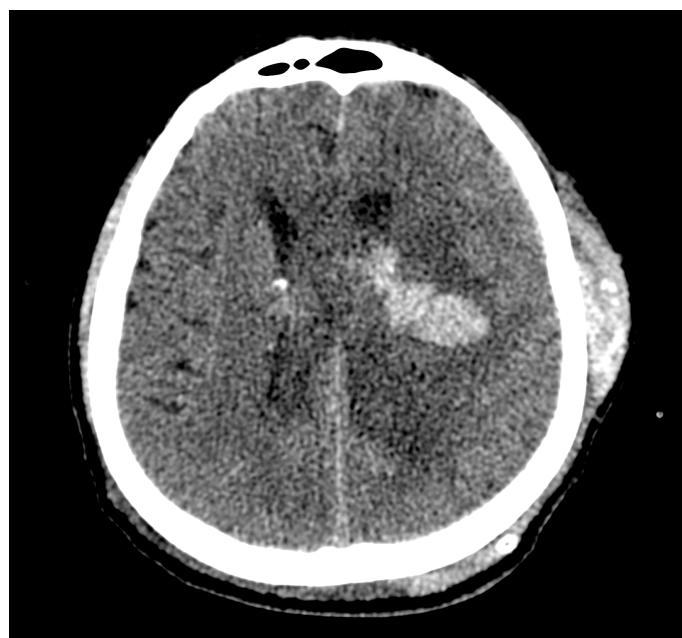


Рис. 5 Иллюстрация смешанного кровоизлияния

2.2. Диагностика внутримозговых кровоизлияний

Компьютерная томография – разновидность рентгенологического исследования. Ее главная особенность в том, что во время обследования создается несколько изображений органа, в то время как при обычной рентгенографии мы видим лишь его тень. Таким образом, информативность КТ в разы выше и достигает показателя 97.5%. Суть метода КТ сводится к созданию послойных изображений. Чаще всего расстояние между слоями не превышает 1-2мм. Лучи проходят через исследуемую область в трех направлениях и улавливаются высокочувствительными датчиками. Полученная информация предварительно обрабатывается и сохраняется в формате DICOM. Итоговая информативность томографии достигает 98%. Сохраненные снимки можно использовать как в цифровом виде, так и произвести печать на пленке.

Принцип работы КТ основан на свойствах рентгеновского излучения, которое по-разному поглощается разными тканями организма. Самый большой коэффициент поглощения имеют костные ткани, поэтому на снимках они видны особенно отчетливо и в светлых оттенках серого. Ткани, близкие по плотности к воздуху, лучи проникают беспрепятственно, и они на снимках изображаются черным цветом. Поэтому для исследования полых органов необходимо контрастное вещество, например барий, которое поглощает лучи и позволяет увидеть структурные особенности органа на снимках и построить объемную компьютерную модель.

Результаты, получаемые датчиками системы, обрабатываются и визуализируются с применением компьютерных программ. Таким образом компьютерная томография представляет собой программно-аппаратный комплекс включающий в себя рентген и достаточно сложное программное обеспечение. Принцип работы системы компьютерной томографии представлен на рис. 6.

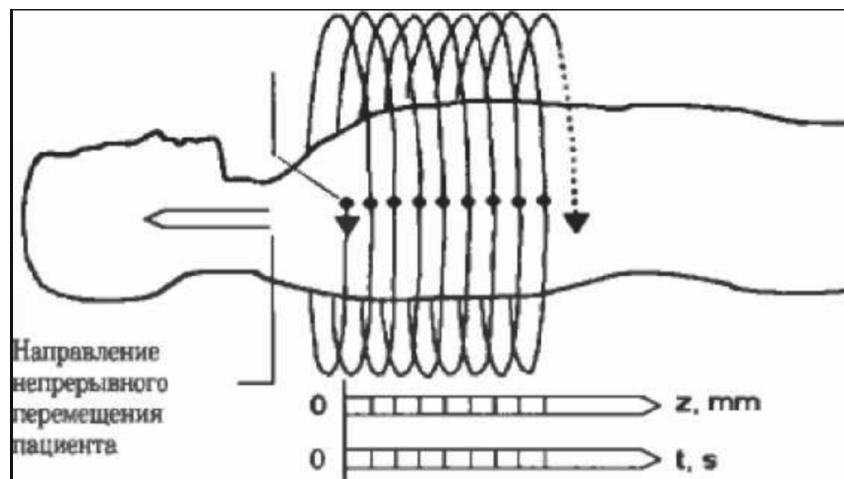


Рис. 6 Принцип работы системы компьютерной томографии

КТ исследование позволяет обнаружить практически любую патологию всех внутренних органов организма человека, например:

- врожденные пороки развития;
- приобретенные заболевания;
- новообразования;
- инородные тела;
- кровотечения;
- камни в органах (почки, мочевой пузырь);
- воспалительные изменения в костной и мягких тканях;

Также компьютерная томография имеет ряд следующих достоинств:

- назначают для определения изменений в органах и тканях, если их нельзя обнаружить другими методами исследования;
- возможно исследование любой области тела, в том числе и те которые нельзя хорошо просмотреть с помощью рентгенографии;
- выявляет онкологические, инфекционные заболевания, множество других болезней;
- помогает оценить результаты медикаментозного и хирургического лечения.

2.3. DICOM

DICOM (Digital Imaging and COmmunications in Medicine) – это стандарт обработки, хранения, печати и передачи информации в системах медицинской визуализации. Он включает описание формата файлов и сетевой протокол. Сетевой протокол использует TCP/IP в своей основе для коммуникации между системами. Также, системы, поддерживающие чтение и запись файлов DICOM, могут обмениваться между собой файлами в формате DICOM. Владельцем стандарта является американская организация National Electrical Manufacturers Association (NEMA). Он разрабатывается комитетом стандарта DICOM, состоящим из нескольких рабочих групп (WG).

В данном исследовании используются файлы в формате DICOM. Структура файла представлена на рис. 7.

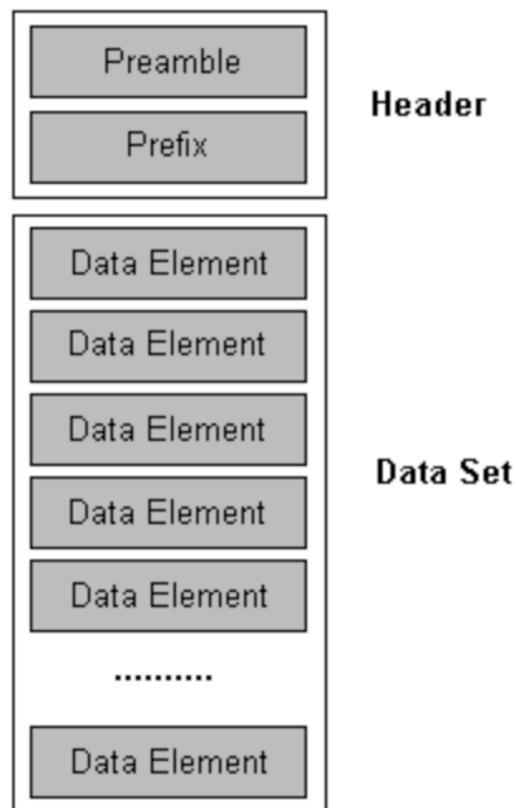


Рис. 7 Обобщенная структура файла DICOM

DICOM файл состоит из двух основных частей: заголовка и блока данных. Заголовок можно представить в виде пары ключ-значение. Например, “Patient ID”: “123098”, “Image Number”: “1” и т. д. Блок данных можно представить в виде контейнера, куда может быть помещен файл любого формата. Например изображение в формате JPG или PNG, или архив *.ZIP.

2.4. Возможности стандарта DICOM

Для организации эффективной работы требуется больше, чем простое соединение оборудования через кабели. Необходимо комплексное решение по управлению всей диагностической информацией, начиная с ввода изображений и заканчивая архивацией. Стандарт DICOM позволяет решить задачи интеграции на основе открытой архитектуры. DICOM позволяет организовать не только пересылку данных по сети, но и автоматическую обработку данных. Он значительно уменьшает время подготовки и проведения исследований, управления изображениями и сопутствующей информацией. Для достижения наивысшей эффективности, он поддерживает все стадии диагностики, снижая себестоимость за счет:

- сокращения времени обслуживания;
- отказа от пленок и затрат на их хранение;
- резкого сокращения потерь изображений и результатов.

Стандарт DICOM (DICOM Протокол) обеспечивает связь между диагностическим оборудованием различных производителей и DICOM Серверами, включая:

- Рентгенологическую аппаратуру,
- Ангиографические комплексы,
- Компьютерные Томографы,
- Магнитно-Резонансные Томографы,
- Изотопные сканеры,
- Ультра-Звуковые сканеры,
- Микроскопы, эндоскопы и т.п.
- Рабочие DICOM станции.

Файловый уровень стандарта DICOM 3.0 описывает:

- Данные пациента,
- Фирму и модель изготовителя прибора,
- Данные медицинского учреждения,
- Данные персонала,
Вид обследования и дата/время его проведения,
- Параметры и условия проведения обследования,
Параметры изображения, записанного в файле,
- Unique Identifier (UID) - уникальные ключи идентификации групп данных, описанных в файле,
- Изображения, полученные при исследовании пациента,
- PDF-документы в файле,
- Запись на оптические носители,
- Протокол для передачи/приема по компьютерным сетям.

3. Практическая часть

Предложенный метод содержит четыре этапа: обработка изображений, сегментирование изображений, извлечение свойств и классификация

3.1. Набор данных

Для данной работы был подготовлен набор анонимизированных данных, содержащих 100 исследований. В дополнение к каждому исследованию был врачом-рентгенологом указан диагноз. Каждое исследование в среднем содержит около 250 снимков в формате DICOM размером 512*512 пикселей. Толщина срезов составляет 0.75-1.5 мм.

Особенностью данного исследования является поиск и классификация гематом на снимках с сильными патологиями, такими как неправильная форма черепа, отсутствие частей мозга, инородные предметы.

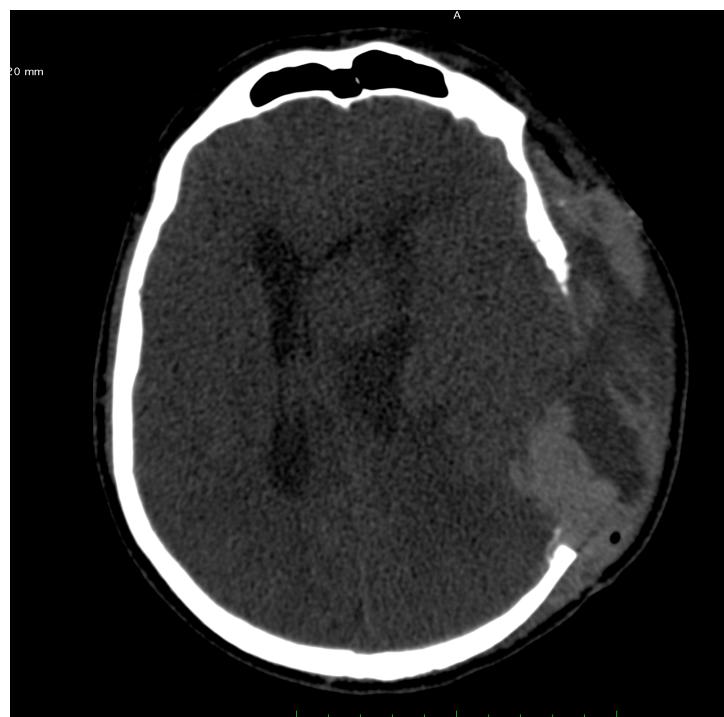


Рис. 8 Пример патологии. На снимке отсутствует правая стенка черепа.



Рис. 9 Пример патологии. На снимке присутствует инородный предмет

3.2. Инструментарий

В данной работе для обработки исследований и создания моделей поиска и классификации применялся язык программирования Python с библиотеками pydicom, jupyter, numpy, scipy, tensorflow, keras, scikit-learn, matplotlib. Для просмотра снимков применялся Horos – программа для просмотра снимков DICOM для MacOS.

3.3. Поиск

3.3.1. Сдвиг средней линии (Mid Line Shift)

Поскольку человеческая голова является грубо симметричной структурой, наблюдение за искажением анатомии средней линии или «средним сдвигом (MLS)», служит удобным инструментом прогнозирования внутричерепного давления [9,10]. Традиционно считается, что степень MLS должна измеряться на уровне отверстия Monro, где перегородка pellucidum служит истинной срединной линией [10]. Его также часто измеряют как расстояние от перегородки pellucidum до идеальной средней линии (рис. 10, 11) в повседневной практике.

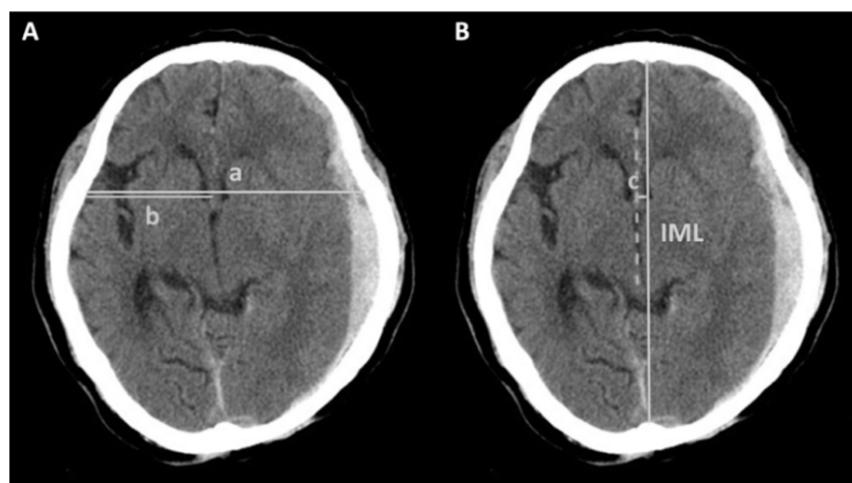


Рис. 10 (A)На уровне межжелудочкового отверстия измеряются ширина черепа («а») и расстояние от черепа до перегородки pellucidum («б»). Сдвиг средней линии рассчитывается как: (а / 2) (B) Идеальная срединная линия (IML) определяется как линия соединения между самой передней точкой переднего фалькса и самой последней точкой заднего фалькса. Далее строится параллельная линия, проходящая через перегородку pellucidum (пунктирная линия), смещение средней линии измеряется как расстояние между этими двумя линиями («с»).

Последний метод измерения принят в нескольких автоматизированных или полуавтоматических методах измерения MLS. Значение MLS с отклонением более 0,5 см, по сравнению с исходным снимком головного мозга является существенным и свидетельствует о появлении негативных неврологических последствий у пациента. Однако в чистом виде использование подхода MLS с абсолютными значениями дает плохой результат. Другими словами, существует большое количество различных форм черепа, а также множество различных возрастных и этнических групп поэтому применения абсолютного значения не является разумным.

Согласно исследованию [11], для увеличения точности диагностики MLS применяется отношение:

$$\text{MLS} / \text{ширина черепа}.$$

Существует два способа измерения MLS [11]: ручной и автоматический. В случае ручного измерения исследование проводится тремя независимыми сертифицированными нейрохирургами. Для каждого набора изображений КТ врачам было предлагается ответить, имеется ли значительный сдвиг средней линии или нет. После этой оценки необходимо указать два параметра: MLS и максимальную внутричерепную ширину (ICWMAX, самое большое значение ширины черепа в одном и том же срезе измерения MLS) в обозначенных срезах, где хорошо видны межжелудочковые отверстия.



Рис. 11 Используемые параметры сдвиг средней линии и максимальная ширина черепа

В случае автоматического измерения необходимо предварительно удалить из исследования снимки, на которых не содержатся или плохо видны межжелудочковые отверстия. Далее необходимо вычислить взвешенную среднюю линию (weighted midline – WML). Эта взвешенная средняя линия представлена просто кривой, соединяющей набор взвешенных средних в каждой строке матрицы изображения. Так же определяется весовой коэффициент w для пикселя x_{ij} для значения в оттенках серого g_{ij} .

$$w(x_{ij}) = e^{-\alpha g_{ij}}$$

$$m(x_i) = \frac{\sum_{j=l_i}^{r_i} x_{ij} w(x_{ij})}{\sum_{j=l_i}^{r_i} w(x_{ij})}$$

После того, как средневзвешенные значения были рассчитаны для каждой строки во внутричерепном регионе, далее выполнялось сглаживание результатов путем усреднения по ее соседям. Для измерения MLS (рис. 12) выбирается сегмент WML около межжелудочкового отверстия. Таким образом, оценка MLS равна максимальному расстоянию от этого сегмента WML до IML.

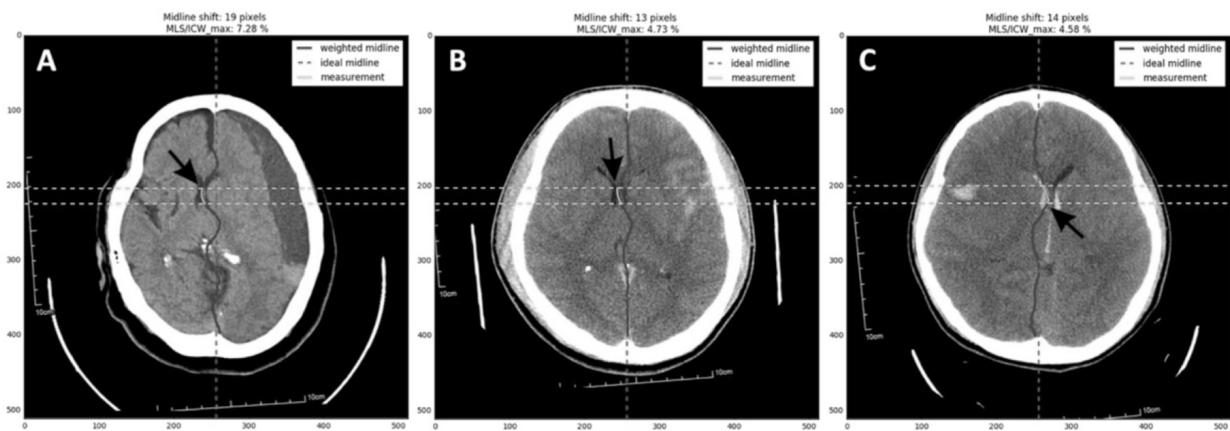


Рис. 12 Примеры измерения MLS с применением вычислительной системы. Иллюстрация взята из статьи [11]

3.4. Классификация

3.4.1. Подготовка снимков

Снимки компьютерной томографии требуют предварительной подготовки, чтобы убрать бесполезную информацию со снимков и увеличить интенсивность исследуемых областей. Подготовка снимков состоит из следующих этапов:

- Преобразование изображений в оттенки серого
- улучшение черно-белых изображений
- наращивание областей
- изоляция мозга
- удаление шума

3.4.2. Преобразование в оттенки серого

Исходные снимки исследования обрезаются до необходимого размера и преобразовываются из RGB снимков размером $512 * 512 * 3$ в черно-белые снимки размером $512 * 512$.

3.4.3. Улучшение черно-белых изображений

Отличие изображений низкой циркуляцией оттенков серого на первом снимке. В связи с этим дифференцированное расширение связано с увеличением динамического диапазона оттенков серого в изображениях. Улучшение изображений изменяет изображения $im1$ под $im2$ используя T , где T - функция изменения, а r и s используются для обозначения оценок пикселей в изображениях f и g по отдельности. Значения пикселей r и s связаны выражением:

$$s = T(r)$$

Результат данного преобразования сохраняется в черно-белые снимки.

Таким образом, результаты снова отображаются в диапазон $[0, L - 1]$, где $L = 2^k$, k - количество бит в рассматриваемом изображении.

3.4.4. Улучшение линейного контраста

Используя функцию $g(f)$, получается новое изображение B от данного изображения A посредством преобразования

$$B(i,j) = g(A(i,j))$$

где $i = 0, \dots, N - 1, j = 0, \dots, M - 1$.

Функция $g(f)$ применяется для каждого пикселя в отдельности. Значение оттенка серого f в каждом пикселе принимает значение $g(f)$:

$$g(f) = af + b$$

Исходное изображение и гистограмма приведены на рис. 13.

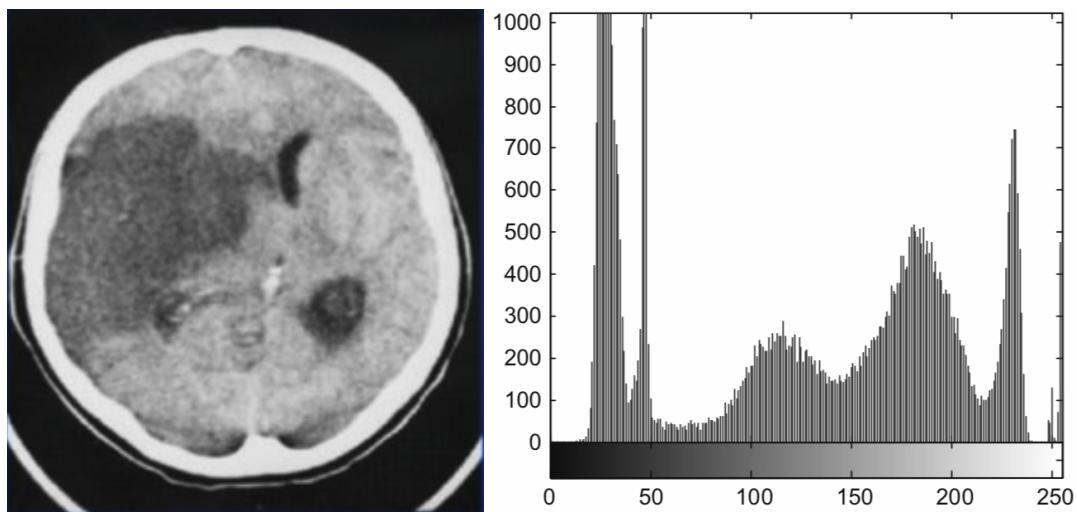


Рис. 13 Исходное изображение и его гистограмма

Как можно заметить, гистограмма содержит несколько пиков. В основном левый пик соответствует пикселям фона, а правый - тонким тканям. Наиболее полезная информация для исследования содержится в правой части гистограммы. Метод линейного контрастного растяжения применяется в требуемой области для улучшения видимости изображения, как показано на рис. 14.

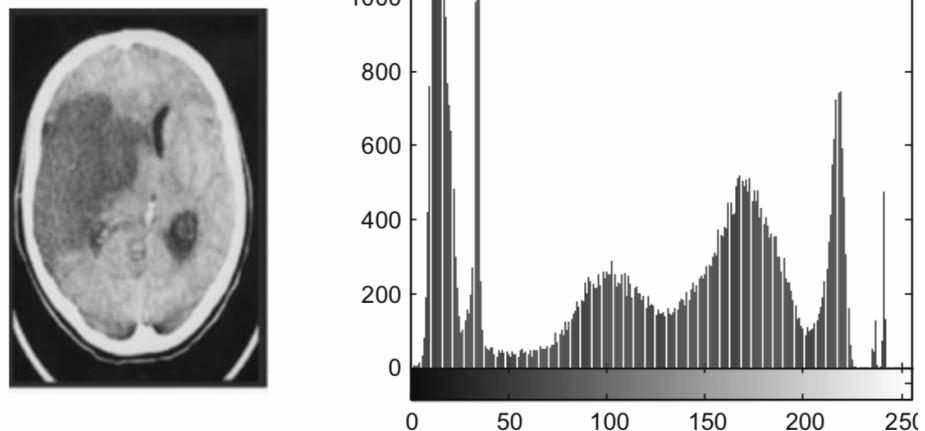


Рис. 14 Результатирующее изображение и гистограмма

При линейном контрастном растяжении контраст изображения недостаточен, чтобы сделать его текстуру прозрачной. Для улучшения контраста изображения применяется степенная функция.

3.4.5. Улучшение изображения с применением степенного закона

Этот подход называется гамма-поправкой. Для разных оценок γ могут применяться различные уровни обновления в соответствии с выражением:

$$s = cr^\gamma$$

Устанавливая значения вариационной гаммы можно получить изображения различной интенсивности и четкости. Улучшение изображения с применением степенной функции дает лучшие результаты, в сравнении со случаем, когда используется линейная функция.

3.4.6. Увеличение регионов и выделение области с мозгом

Близко расположенные области, имеющие одинаковый уровень интенсивности, объединяются, образуя более большие области. Чтобы вычислить зону белого вещества в черепе, используется уровень интенсивности как показано на рис. 15.

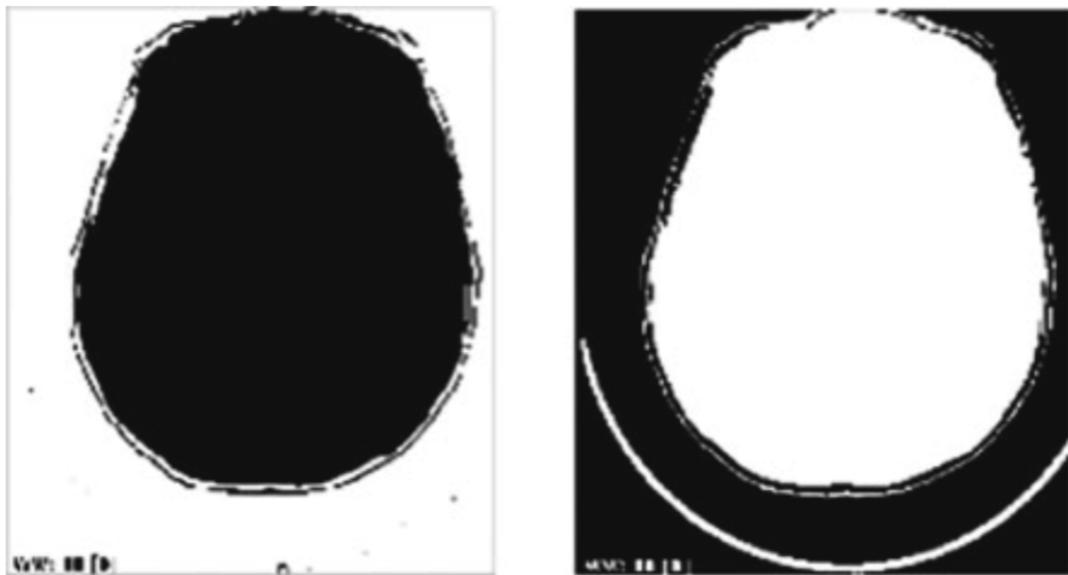


Рис. 15 Область изображения с мозгом и без мозга

После визуализации следующим шагом будет определение и удаление частей черепа.

Для удаления кости черепа морфологические операции, такие как логическое «ИЛИ» и логическое «И», используются. Далее приведены этапы, описывающие удаление части черепа с исходного изображения.

- Получаем на вход изображение $O(p, q)$ и измеряем размер полученного изображения
- Представим изображение содержащее костную ткань, как $S(k, l)$ из изображения $O(p, q)$ используя следующие преобразование: пусть $m = p, n = q$. Тогда $E(i,j) = O(i,j)$ для $S(i,j) > T$
- $E_Removal(i,j) = \text{diff}[O(i,j) \text{ и } S(i,j)]$, где $E_Removal$ является частью исходного изображения в котором содержится костная ткань.

3.4.7. Удаление шума

Метод медианной фильтрации применяется для избавления от шумов и свободных пикселей без потери резкости с целью улучшения качества снимков и устранения аномалий. На изображении используется медианный фильтр с окном $[3 \times 3]$ для удаления импульсного шума на снимке, как показано на рис.16.

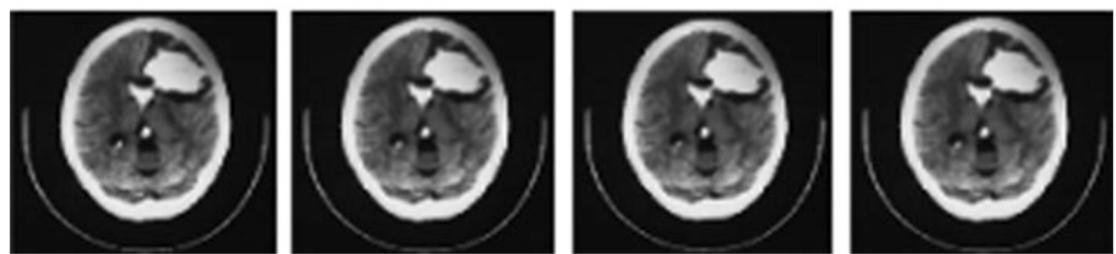


Рис. 16 Результат применения четырехкратной медианной фильтрации

3.4.8. Метод предварительной сегментации

Если изображения содержат похожие характеристики, они могут быть сегментированы на несколько регионов. В предлагаемой системе используется методы разделения и слияния регионов. Обобщенный алгоритм представлен следующими этапами:

Пусть ‘Р’ — это шанс быть первым изображением, а ‘Т’ - конкретным предикатом, $\text{flag0} = \text{точный}$, $\text{flag1} = \text{неточный}$, таким образом:

- Исходный регион эквивалентен Р
- Каждый регион разбивается на квадранты для каждого $T(\text{Reg}_i) = \text{flag1}$
- Каждый регион $T(\text{Reg}_j) = \text{flag0}$ и производится объединение смежных регионов Reg_i и Reg_j , для которых выполняется $T(\text{Reg}_i \cup \text{Reg}_j) = \text{flag0}$
- Предыдущий шаг повторяется до тех пор, пока не произойдет слияние.

Исходное изображение разбивается на 4 части. Полученные сегменты и их гистограммы приведены на рис. 17 и 18.

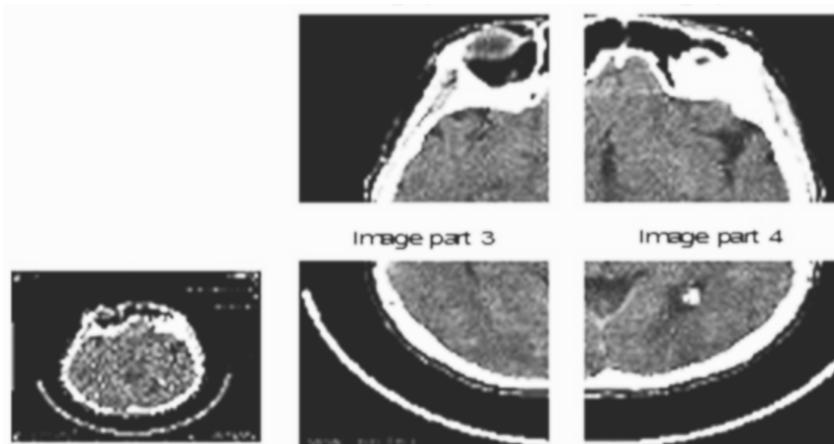


Рис. 17 Результат предварительной сегментации

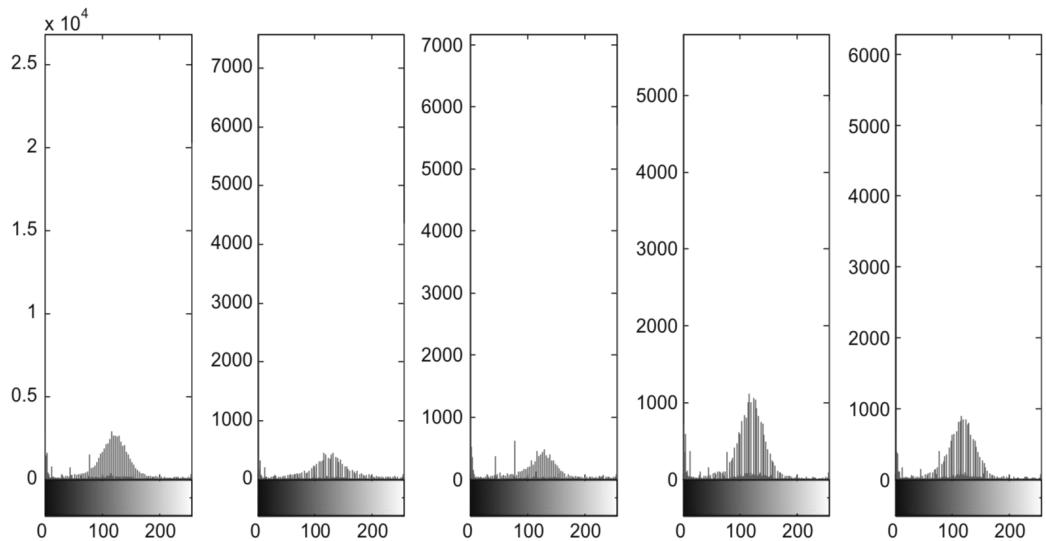


Рис. 18 Гистограммы сегментированного каждого из сегментированных участков

Одна часть из четырех частей из приведенного изображения, которая имеет вероятность аномальных областей, разбивается на четыре дополнительные части, используя статистическую функцию, пока не выполнится группировка.

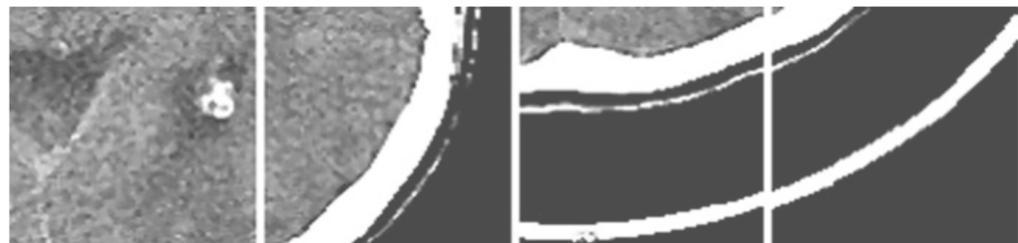


Рис. 19 Сегментация второго уровня.

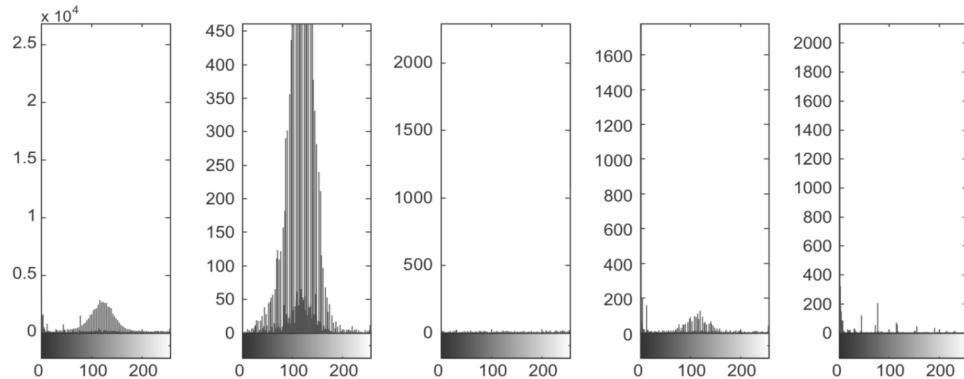


Рис. 20 Гистограмма фрагментов снимка, полученных в ходе сегментации второго уровня

Используемая предварительная сегментация позволяет избежать поиска в ненужных регионах. Далее приведен псевдокод для этапа сегментации.

1. Полученное изображение сохраняется в виде 2D-матрицы.
2. Изображение делится на 4 части.
3. Вычисляются гистограммы и находятся значения пикселей для каждой из частей.
4. Сравниваются гистограммы и значения пикселей с каждой частью чтобы получить гистограмму с наибольшим значением пикселей.
5. Для нахождения аномального региона, выбирается наибольшее значение пикселя гистограммы, среднее значение и стандартное отклонение разложенного изображения.
6. Для более точного нахождения области, необходимо повторить шаги 2-5.

Таким образом, можно сказать, что область кровоизлияния имеет среднее значение, которое выше, чем другие у остальных областей. Часто используемые статистические функции – это среднее и стандартное отклонение, и они используются для различения нормальных и ненормальных областей. Среднее значения – это сумма всех пикселей, деленная на общее количество пикселей в изображении. Стандартное отклонение – это отклонение от среднего значения.

$$P(i) = \frac{H(i)}{NM}$$

Среднее значение

$$\mu = \sum_{i=1}^{G-1} iP(i)$$

Стандартное отклонение

$$\sigma^2 = \sqrt{\sum_{i=1}^{G-1} (i - \mu)^2 P(i)}$$

Среднее значение и стандартное отклонение для каждой из четырех частей приведено в таблице:

Номер сегмента	1	2	3	4
Ср. значение	39.2090	43.7209	53.112	57.6100
Стандартное отклонение	81.1022	82.0176	80.6726	77.2007

На рис. 21, 22 приведено статистическое распределение стандартного отклонения и среднего значения. В данной работе, гистограмма со значением пикселя 450 считается аномальным регионом.

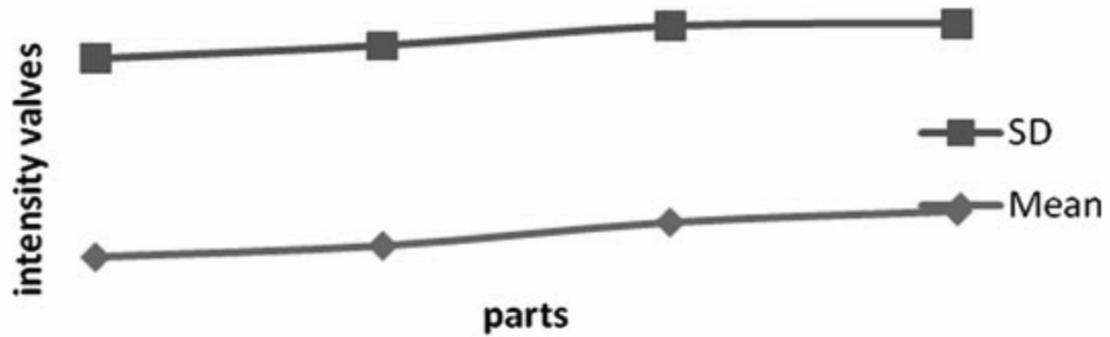


Рис. 21 Статистическое распределение стандартного отклонения и среднего значения.

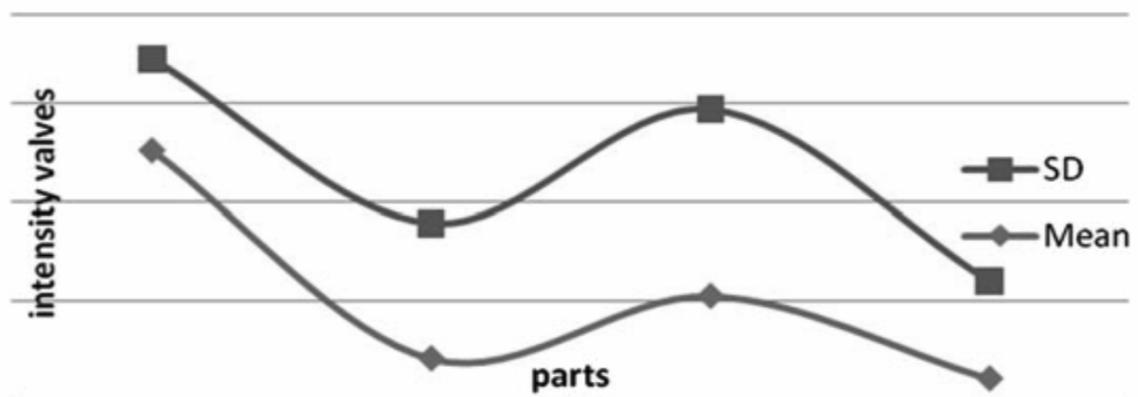


Рис. 22 Статистическое распределение стандартного отклонения и среднего значения для второго уровня декомпозиции

Номер сегмента	1	2	3	4
Ср. значение	126.3472	21.5217	53.1893	11.3315
Стандартное отклонение	45.5955	68.1509	93.4810	49.3669

Этап предварительной сегментации делает основной процесс сегментации более быстрым, чем при отсутствии предварительной подготовки.

3.5. Извлечение свойств

Основной причиной применения этапа извлечения свойств является уменьшение количества исходных данных путем определения некоторых параметров и свойств, которые отличают один набор пикселей от другого. Для достаточно эффективного решения этой задачи можно применить матрицу совпадений в оттенках серого (GLCM).

Несмотря на высокую производительность GLCM, извлечение свойств занимает много времени. Чтобы устранить данный недостаток, применяется вейвлет преобразование (wavelet change, DWT and PWT). чтобы разбить изображения на 4 блока информации и после применять GLCM для каждого из блоков.

3.5.1. Дискретное вейвлет преобразование (Discrete Wavelet Transform - DWT)

Вейвлет-преобразование – преобразование, похожее на преобразование Фурье (или гораздо больше на оконное преобразование Фурье) с совершенно иной оценочной функцией. Основное различие лежит в следующем: преобразование Фурье раскладывает сигнал на составляющие в виде синусов и косинусов, т.е. функций, локализованных в Фурье-пространстве; напротив, вейвлет-преобразование использует функции, локализованные как в реальном, так и в Фурье-пространстве. Другими словами, Анализ Фурье – это разложение сигнала на синусоидальные волны различных частот. Аналогично, вейвлет-анализ – это разложение сигнала на сдвинутые и масштабируемые версии первоначального (или материнского) вейвлета. Математически процесс анализа Фурье представлен преобразованием Фурье:

$$F(a) = \int_{-\infty}^{\infty} f(t) \times e^{-i\omega t} \times d \times t,$$

которое является суммой по времени сигнала $f(t)$, умноженного на комплексную экспоненту. Результатами этого преобразования являются коэффициенты Фурье $F(w)$, умножение которых на синусоиду соответствующей частоты даст синусную компоненту исходного сигнала.

Аналогично, непрерывное прямое вейвлет-преобразование определяется как сумма по времени сигнала, умноженного на масштабируемые, сдвинутые версии вейвлет-функции:

$$N(\tau, a) = \frac{1}{\sqrt{a}} \times \int_{-\infty}^{\infty} f(t) \times \psi \times \frac{t - \tau}{a} \times d \times t$$

где $\psi(t)$ – вейвлет-функция, $f(t)$ – сигнал.

Результатом будут вейвлет-коэффициенты $C(t, a)$, которые являются функцией позиции t и масштаба a . Умножением каждого коэффициента C на соответственно масштабируемый и сдвинутый вейвлет получают непосредственные вейвлеты исходного сигнала

После применения DWT изображение разбивается на 4 подгруппы, приведенные на рис. 23.

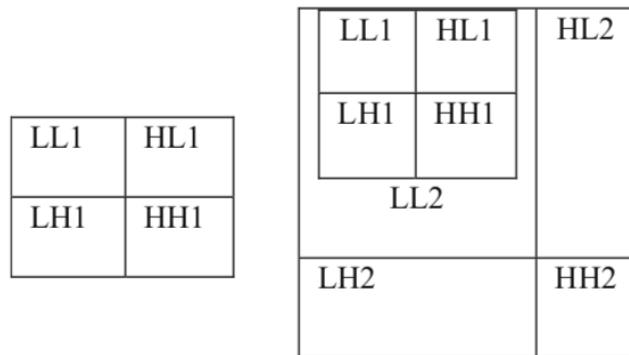


Рис. 23 Схематичное представление дискретного вейвлет преобразования

Двумерное дискретное вейвлет-преобразование получается при помощи применения одномерной модификации последовательно к столбцам и строкам изображения.

В результате объединения итогов работы обеих ветвей алгоритма получается монохромное контурное изображение, на котором линии соответствуют характерным особенностям исходного образа.

Исходная матрица представляется в виде набора строк, каждый элемент этого набора имеет длину, совпадающую с шириной изображения, а элементы векторов принимают целочисленные значения в диапазоне от 0 до 255. Такая последовательность шагов приводит к набору векторов, содержащих вейвлет-образы строк матрицы исходного изображения. Вейвлет-коэффициенты могут принимать значения в широких пределах; из позиции выбираем только позиции локальных максимумов.

В конечном счете получаем одну низкочастотную полосу и три высокочастотных, высокочастотные коэффициенты каждой полосы отвечают за определенное расположение — диагональное, вертикальное, горизонтальное.

3.5.2. Матрица совпадения серого уровня (Gray-Level Co-occurrence Matrix - GLCM)

GLCM представленная в виде $C(i, j, d, \Theta)$ говорит о вероятности совпадения пикселей. Параметры i, j - уровни серого. Значение параметр d может принимать значения от 1 до максимального размера изображения. Значение Θ может быть приведено к нормальным значениям 0, 45, 90, 135 градусов. После вычисления GLCM, применяется алгоритм извлечения текстурных признаков харалика. Пример свойств указан в таблице:

Свойство	Аномальный вес	Нормальный вес
Контраст	2.1234	1.3451
Корреляция	0.7942	0.7812
Энергия	0.1833	0.1801
Гомогенность	0.7455	0.7109
Цельность	0.0732	0.0167
Энтропия	0.8101	0.7451
Дисперсия	2.34E + 04	1.14E + 03
Перекос	1	1
Среднее значение	118.2191	107.31
Стандартное отклонение	43.3342	74.402

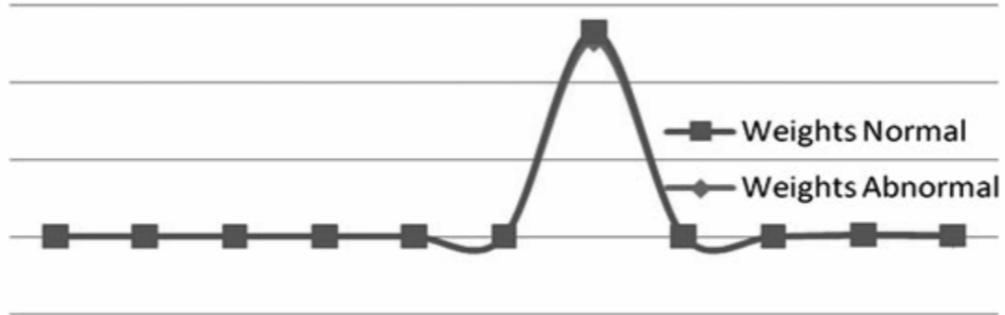


Рис. 24 Статистическое распределение нормальных и аномальных весов

Энтропия

$$H = - \sum_{i=1}^{G-1} p(i) \log_2 [P(i)]$$

Энергия

$$E = \sum_{i=1}^{G-1} (p(i)) 2$$

Дисперсия

$$\sigma^2 = \sum_{i=1}^{G-1} (i - \mu)^2 P(i)$$

Перекос

$$\sigma^{-3} = \sum_{i=1}^{G-1} (i - \mu)^3 P(i)$$

Контраст

$$\sum_{i=1}^G \sum_{j=1}^G P(i,j)$$

3.5.3. Извлечение свойств используя LDA (Латентное размещение Дирихле - Latent Dirichlet Allocation)

Извлечение свойств является способом уменьшения размерности и широко используется для интеллектуального анализа данных и поиска знаний и позволяет исключить нерелевантные избыточные функции.

Существуют различные системы определения свойств, однако в данной работе используется LDA. LDA включает определение подмножества d - компонентов из суммы элементов D . Ограничение компонентных векторов процедурой объединения позволяет увеличить показатели точности, а также уменьшить непредсказуемость и количество вычислительного времени. D обозначает не обычные по критериям числа от 1 до D , и совокупное распределение может быть представлено в виде $S = \{1, 2, \dots, D\}$.

$$S = X \cup Y$$

X означает подмножество выбранных компонентов, а Y означает расположение остаточных элементов. $K(X)$ обозначает функцию, оценивающую производительность подмножества, выбранного из признаков X .

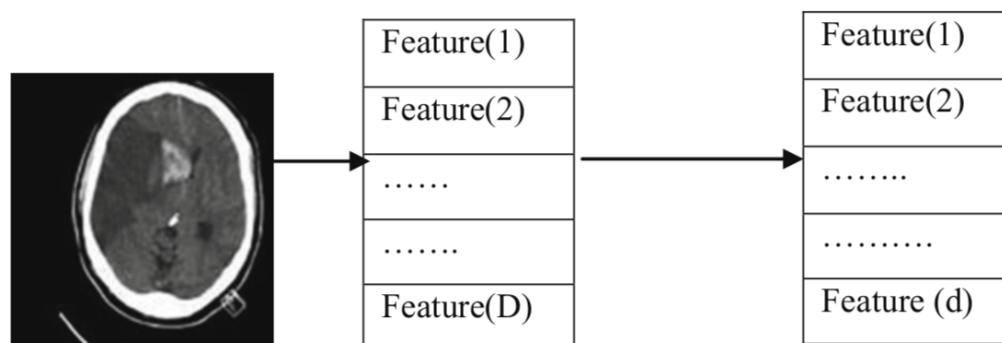


Рис. 25 Процесс извлечения свойств из снимка

3.6. Классификация

3.6.1. Нейронные сети

Нейронная сеть — это последовательность нейронов, соединенных между собой синапсами. Структура нейронной сети берет начало из биологии. Нейронные сети также способны анализировать входящую информацию и воспроизводить ее из своей памяти. Другими словами, нейросеть это машинная интерпретация мозга человека, в котором находятся миллионы нейронов, передающих информацию в виде электрических импульсов.

3.6.1.1. Область применения

Нейронные сети используются для решения сложных задач, которые требуют аналитических вычислений подобных тем, что делает человеческий мозг. Самыми распространенными применениями нейронных сетей является:

Классификация — распределение данных по параметрам. Например, на вход дается набор людей и нужно решить, кому из них давать кредит, а кому нет. Эту работу может сделать нейронная сеть, анализируя такую информацию как: возраст, платежеспособность, кредитная история и т.д.

Предсказание — возможность предсказывать следующий шаг. Например, рост или падение акций, основываясь на ситуации на фондовом рынке.

Распознавание — в настоящее время, самое широкое применение нейронных сетей. Используется в Google, когда вы ищете фото или в камерах телефонов, когда оно определяет положение вашего лица и выделяет его и многое другое.

3.6.1.2. Типы нейронных сетей

Сети прямого распространения – все связи этой сети имеют строгое направление от входных нейронов к их выходам. Среди таких сетей хочется отметить: простейший персепtron автором которого является Фрэнк Розенблatt и многослойный персепtron.

Нейронные сети Реккурентного типа – данные с выходных нейронов или из скрытого слоя передается частично обратно на входные нейроны.

Радиально базисные функции – это нейронная сеть, в основе которой является наличие скрытого слоя из радиальных элементов и выходного слоя из линейных элементов. Такие сети довольно компактны и обучаются достаточно быстро.

Сверточные нейронные сети. Название архитектура сети получила из-за наличия операции свёртки, суть которой в том, что каждый фрагмент изображения умножается на матрицу (ядро) свёртки поэлементно, а результат суммируется и записывается в аналогичную позицию выходного

3.6.2. Классификатор на основе искусственной нейронной сети

В этом предлагаемом методе применяется нейронная сеть прямого распространения с обучением на основе алгоритма обратного распространения ошибок рис. 25. Каждый узел имеет связь с каждым узлом из предыдущего и последующего слоя. Нейроны входного слоя связываются со всеми нейронами первого скрытого слоя. Нейроны выходного слоя связаны со всеми нейронами последнего скрытого слоя.

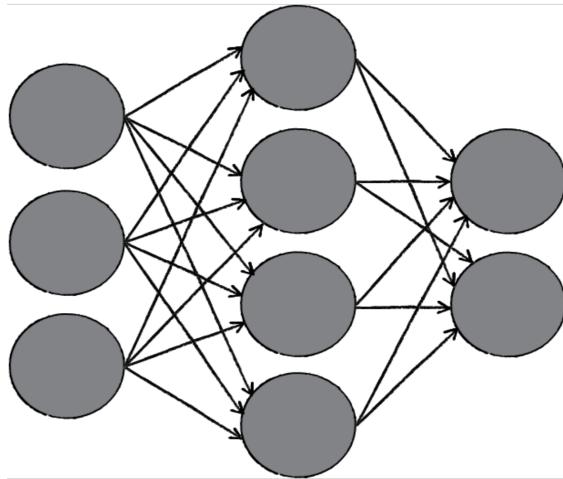


Рис. 26 Схематичное изображение нейронной сети. В данном случае приведен пример полносвязной НС. Круги представляют собой узлы. Стрелкой указываются связи между узлами. Три вертикальных ряда кругов представляют собой три слоя: Входной, Скрытый, Выходной.

Ошибка распространяется по сети в обратном направлении, а веса балансируются по ходу обучения системы. То есть нейронная сеть в ходе процесса обучения будет минимизировать ошибку эту ошибку, выполняя оптимизацию весов. Сеть считается обученной, когда величина ошибки минимальна.

Алгоритм обратного распространения (BP - Back Propagation) регулярно используются для обучения приложений ANN, и данный алгоритм состоит из двух этапов: при инициализации выполняется прямой проход и затем при

обратном проходе вычисляется значение ошибки на выходном слое, которое затем используется для уравновешивания весов.

Цикл уравновешивания будет повторяться до тех пор, пока значение ошибки не будет минимальным.

$$\Delta W_{ji}(n+1) = \eta (\delta_{pj} O_{pi}) + \alpha \Delta W_{ji}(n)$$

где η - скорость обучения, n - количество итераций, α - момент, δ_{pj} - сигнал ошибки.

3.6.3. Метод опорных векторов (Support Vector Machine (SVM))

Classifier Using LS-SVM)

SVM – эффективный регулируемый классификатор с точной стратегией обучения. Основная идея метода — перевод исходных векторов в пространство более высокой размерности и поиск разделяющей гиперплоскости с максимальным зазором в этом пространстве. Две параллельных гиперплоскости строятся по обеим сторонам гиперплоскости, разделяющей классы. Разделяющей гиперплоскостью будет гиперплоскость, максимизирующая расстояние до двух параллельных гиперплоскостей. Алгоритм работает в предположении, что чем больше разница или расстояние между этими параллельными гиперплоскостями, тем меньше будет средняя ошибка классификатора.

Обобщенный алгоритм:

- 1) Тренировочный набор данных представляется в виде N точек вида $\{x_k, d_k\} k = 1$, входные данные $x_k \in X$ с меткой класса $d_k \in D = \{-1, +1\}$
- 2) Далее применяется n-кратная ($n=7$) процедура кросс-валидации для получения тренировочного и тестового набора данных
- 3) Выбирается функция ядра K и выполняется обучение LS-SVM классификатора
- 4) Далее выполняется классификация тестовых изображений на нормальные и не нормальные.

3.6.4. Классификатор на основе сверточной нейронной сети

Сверточные нейронные сети широко применяются в области компьютерного зрения [1,2]. В основе сверточных нейронных сетей применяется операция свертки на нескольких слоях иерархии. Обучение такого типа нейронных сетей происходит без учителя, и требует большого количества итераций (или эпох), для получения оптимальных результатов обучения. На каждой итерации из набора тренировочных данных выбираются поднаборы, которые подаются на вход сети. Далее используя подход обратного распространения ошибки, корректируются веса.

Основное отличие от остальных нейронных сетей состоит в том, что на этапе предобработки не производится извлечение свойств, как было описано выше. Данный подход требует большее количество вычислительных ресурсов, по сравнению с нейронными сетями других типов, однако уменьшается объем ручной работы по подготовке снимков и подборе оптимальных параметров для выделения свойств.

На вход нейронной сети подаются нормализованные снимки исследований, обладающие общими признаками. Например, в нашем случае, это может быть набор снимков, содержащих эпидуральные гематомы. Чем больше снимков в тренировочном датасете, тем точнее будет конечный результат.

3.6.4.1. Предобработка

На этапе предобработки необходимо убрать лишние данные, такие как шумы, участки вне черепа и т д. Очищенные изображения обрезаются до размера 512 * 512 пикселей. Дополнительно на этапе предобработки применяется операция усиления контраста. Результирующее изображение $I_{ce}(x, y; \sigma)$ описывается следующим выражением

$$I_{ce}(x, y; \sigma) = \alpha I(x, y) + \beta G(x, y; \sigma) * I(x, y) + \gamma$$

где * - оператор свертки, $G(x, y; \sigma)$ - Гауссовый фильтр.

Значения параметров подбираются эмпирически. Например, $\alpha = 3$, $\beta = -3$, $\sigma = 512 / 30$. Далее, обработанные изображения подаются на вход нейронной сети

3.6.4.2. Архитектура сверточной нейронной сети

Сверточная нейронная сеть является комбинацией слоев разного типа, таких как: сверточный, слой пуллинга, полносвязный слой, слой бинарной классификации.

3.6.4.2.1. Слои сверточной нейронной сети

Для решения различных задач классификации применяется комбинирование слоев разного типа.

Операция свертки извлекает различные свойства на входе. Первый сверточный слой извлекает низкоуровневые свойства, такие как границы, линии, углы. Слои более высокого уровня извлекают более абстрактные свойства. На рис. 27 показана операция трехмерной свертки, применяемая в нейронных сетях.

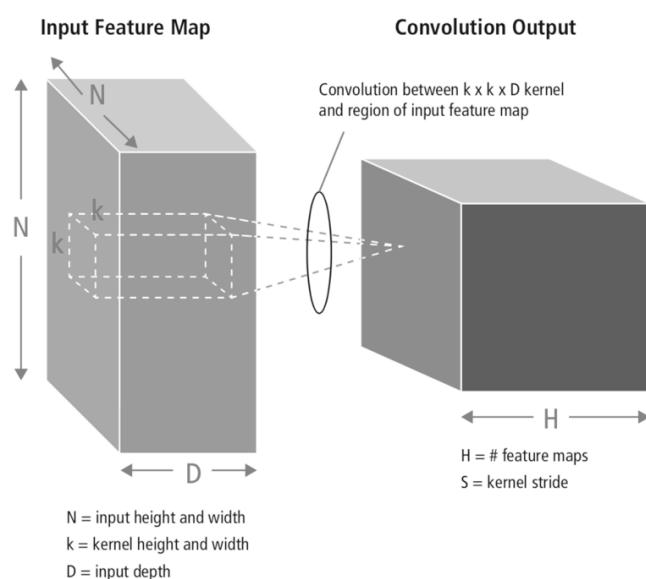


Рис. 27 Схематичное представление процесса свертки

Вход имеет размер $N \times N \times D$ и после операции свертки преобразуется в ядра H , каждый из которых имеет размер $k \times k \times D$. Свертка с одним ядром дает одно выходное свойство, соответственно при использовании H ядер, получаем H выходных свойств. Начиная из верхнего-левого угла входных данных, ядро перемещается по одному элементу по направлению вниз. Затем ядро перемещается с лева-направо на один элемент и снова происходит считывание по направлению вниз.

Этот процесс повторяется пока не будет достигнуть нижний правый угол. Например, когда $N=32$, а $k = 5$, существует 28 позиций в направлении сверху-вниз, и 28 позиций слева направо. Соответственно, каждое свойство на выходе будет содержать 28×28 элементов $((N-k+1) * (N-k+1))$.

Для каждой позиции ядра применяется операция скользящего окна, где $k \times k \times D$ входных элементов и $k \times k \times D$ элементов ядра попарно перемножаются и накапливаются. Таким образом, для создания одного выходного признака требуется $k \times k \times D$ операций умножения и накопления.

3.6.4.2.2. Pooling/subsampling layers

Данный слой уменьшает размер выходных свойств. Это позволяет увеличить устойчивость свойств к шуму и искажениям. Существует два способа для пулинга: max pooling и avg pooling. В обоих случаях данные на входе разделяются на непересекающиеся двумерные пространства (рис. 28).

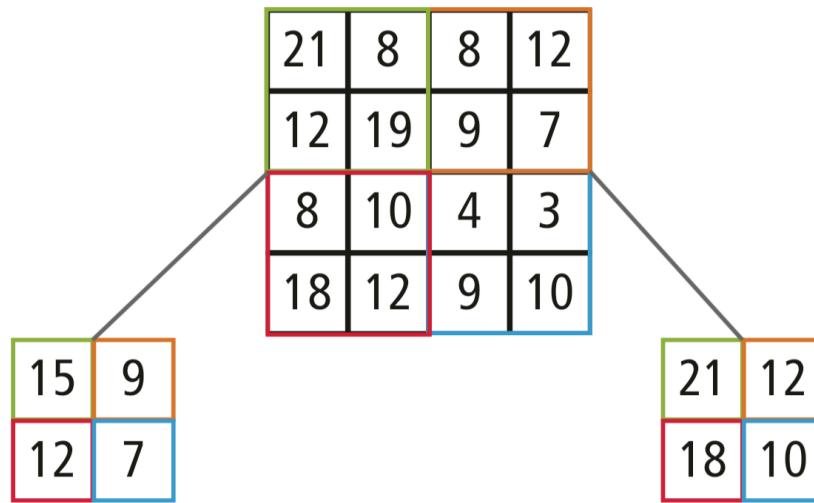


Рис. 28 Схематичное представление операции пуллинга

Каждое входное свойство размером 28x28 и разделяется на 14*14 регионов размером 2*2. Для Avg pooling, вычисляется среднее значение из значений 4x ячеек. Для Max Pooling, из 4x ячеек выбирается максимальное значение

3.6.4.2.3. Нелинейные слои

Нейронные сети в целом и сверточные нейронные сети (CNN) в частности полагаются на нелинейные триггерные функции для однозначного определения свойств на каждом из скрытых слоев. Сети типа CNN могут использовать различные специфические функции, такие как выпрямленные линейные единицы (ReLU) и непрерывные не линейные функции.

ReLU

Функция ReLU реализует функцию $y=\max(x,0)$, таким образом, что размеры входа и выхода данного слоя остаются одинаковыми. Это увеличивает нелинейные свойства функции принятия решения и всей сети, не влияя на поля сверточный слой (рис. 29). По сравнению с другими нелинейными функциями, используемыми в CNN (например, гиперболическим касанием, абсолютном гиперболического тангенса и сигмоида), преимущество ReLU заключается в том, что сеть тренируется во много раз быстрее.

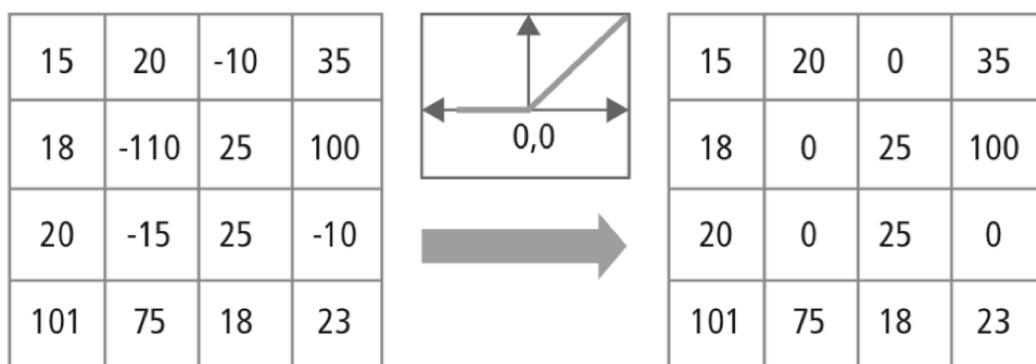


Рис. 29 Пример работы функции активации ReLU

Непрерывная триггерная(нелинейная) функция

Нелинейный слой преобразует каждый отдельный элемент в каждом признаке. Непрерывная триггерная функция может быть гиперболическим тангенсом, абсолютным гиперболическим тангенсом, сигмоидой. На рис. 30, 31, 32 показано примеры нелинейной функции активации.

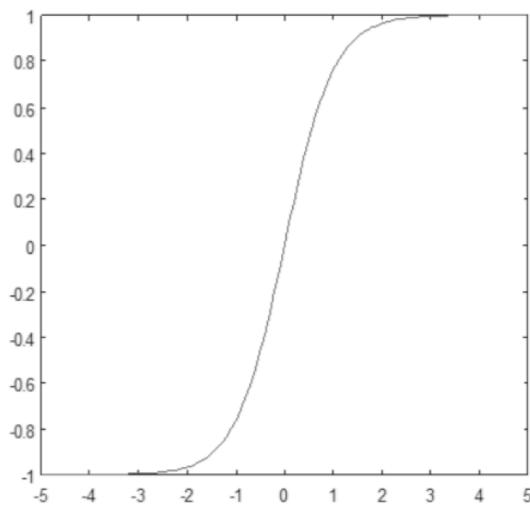


Рис. 30 Гиперболический тангенс

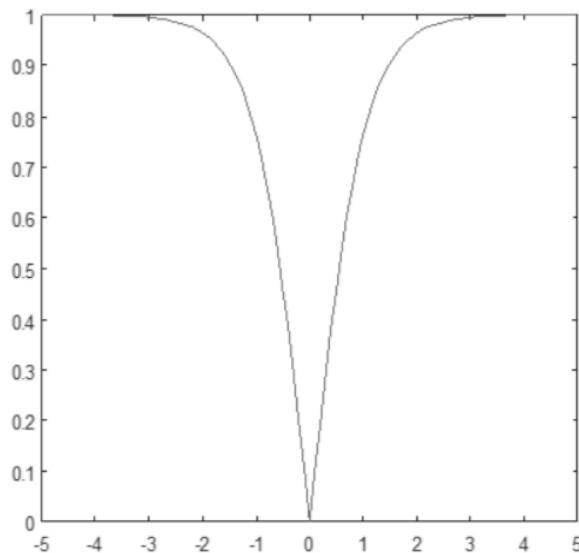


Рис. 31 Абсолютный гиперболический тангенс

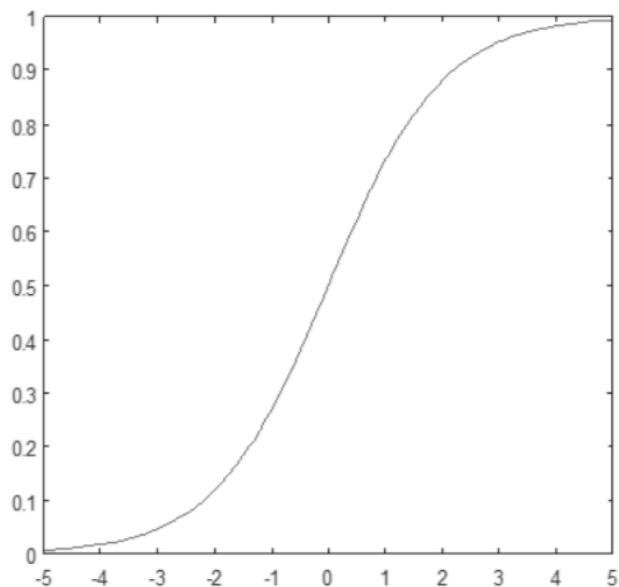


Рис. 32 Сигмоида

3.6.4.2.4. Полносвязный слой

Полносвязные слои часто используются в качестве окончных слоев CNN. Эти слои математически суммируют веса предыдущего слоя признаков и указывают точное сочетания признаков для определения конкретного выходного результата. В случае полносвязного слоя все элементы всех признаков предыдущего слоя используются для расчета каждого элемента из выходного элемента.

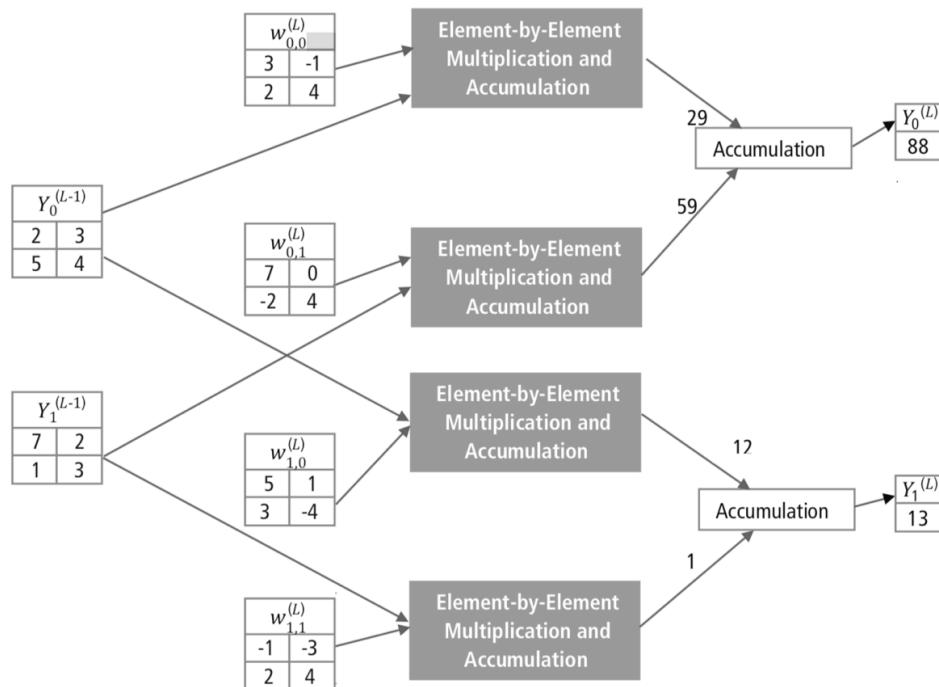


Рис. 33 Схематичное представление полносвязного слоя CNN

На рис. 33 полносвязный слой L. Слой L-1 имеет два свойства размера 2×2 , то есть состоящих из 4x элементов. Слой L имеет два свойства, каждое из которых имеет по одному элементу.

3.6.4.3. Преимущества сверточных нейронных сетей

Устойчивость к сдвигам и шумам на изображении

Обнаружение с применением нейронных сетей устойчиво к шумам, таким, как изменение формы объекта из-за объектива камеры, различные уровни освещения, различные позы, горизонтальные и вертикальные сдвиги и т д. Однако, чтобы обеспечить необходимую инвариантность и устойчивость кискажениям, потребуется большое количество тренировочных данных.

Небольшое потребление памяти

В гипотетическом случае, когда мы используем полносвязный слой для извлечения функций, входное изображение размером 32x32 и скрытый слой, имеющий 1000 функций, потребует порядка 10^6 коэффициентов, и огромного количества памяти. В сверточном слое одни и те же коэффициенты используются в разных местах в пространстве, поэтому потребность в памяти резко уменьшается.

Простое и эффективное обучение

Опять же, используя стандартную нейронную сеть, которая была бы эквивалентна CNN, поскольку количество параметров было бы намного выше, время обучения также увеличивалось пропорционально. В CNN, поскольку число параметров резко сокращается, время тренировки пропорционально уменьшается.

Кроме того, при условии идеального обучения, мы можем разработать стандартную нейронную сеть, производительность которой будет такой же, как у CNN. Но на практике, стандартная нейронная сеть, эквивалентная CNN, будет иметь больше параметров, что приведет к увеличению количества шумов в процессе обучения. Следовательно, производительность стандартной нейронной сети, эквивалентной CNN, будет всегда хуже.

3.7. Оценка результатов эксперимента

Результаты предлагаемого метода оцениваются с использованием следующих мер: чувствительность, специфичность и точность. В исследование использовано три количественные меры для оценки эффективности предлагаемого метода с точки зрения точности, чувствительности и специфичности. Каждый пиксель относится к одному из следующих четырех классов. Истинно положительные (TP), ложно положительные (FP), истинно отрицательные (TN) и ложно отрицательные (FN).

Специфичность может быть получена по следующему выражению

$$\text{Specificity} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

Определяет вероятность того, что аналитический тест является неблагоприятным, учитывая, что у пациента нет заболевания.

$$\text{Sensitivity} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Вероятность показательного теста достоверна, учитывая, что у пациента есть отклонения от нормы.

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Похожесть

$$\text{similarity} = \frac{2\text{TP}}{2\text{TP} + \text{FN} + \text{FP}}$$

Ошибка определения гематомы

$$BR = \frac{A(XOR)S}{S}$$

Однородность

$$Homogeneity = \sum_{i,j} \frac{P(i,j)}{i + (i - j)}$$

Вероятность эффективности аналитического теста.

В приведенной ниже таблице приведены итоговые результаты предложенного подхода. В данном исследовании два классификатора, основанные на обучении с учителем и классификатор с применение сверточных нейронных сетей и обучением без учителя выполняли классификации нормального человеческого мозга и мозга с заболеванием.

Точность классификации составила для MLP 90.1%, SVM 88.6%, CNN 91.8%.

Классификатор	Чувствительность	Специфичность	Точность
MLP	89.7	89.3	90.1
SVM	87.3	90.1	88.6
CNN	89.8	90.3	91.8

4. Заключение

Автоматизированные системы для анализа и классификации медицинских изображений в последнее время становятся все более актуальными. Данный подход является попыткой улучшить точность диагностики врачей и ускорить процесс принятия решений, что впоследствии спасает жизни большего числа пациентов

В ходе выполнения ВКР были получены следующие результаты:

1. Были изучены теоретические основы анализа и обработки изображений, КТ-исследований в формате DICOM
2. Были изучены теоретические основы построения систем с применением нейронных сетей
3. Выполнен предварительный анализ исходных данных
4. Реализован ряд методов по подготовке снимков
5. Реализованы методы сегментации и выделения признаков
6. Реализовано 3 типа классификаторов
7. Проведен анализ полученных результатов

Эксперименты, представленные в этой работе, показали, что после предварительной обработки снимков исследований компьютерной томографии проблема двоичной классификации была решена с точностью 100%.

В дополнение, по результатам эксперимента, можно установить, что классификация с применением сверточной нейронной сети дает наилучший результат. В ходе работы были проведены эксперименты на реальных данных пациентов с применением 3х различных подходов классификации: многослойная нейронная сеть, метод опорных векторов, сверточная нейронная

сеть. Были получены следующие результаты классификации MLP 90.1%, SVM 88.6%, CNN 91.8%.

Для дальнейшего повышения точности поиска и классификации можно использовать большее количество снимков и в большем разрешении, что позволит выявлять еще более мелкие внутримозговые кровоизлияния.

5. Литература

- [1] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [2] J. Schmidhuber, “Deep learning in neural networks: an overview,” *Neural Networks*, vol. 61, pp. 85–117, 2015.
- [3] D. Kovacenic, S. Loncaric, “CT image labeling using simulated annealing algorithm,” *Proceedings of the IX European Signal Processing Conference*, Greece, vol. 4, pp. 2513-2516, 1998.
- [4] Lawrence, Steve, C. Lee Giles, Ah Chung Tsoi, and Andrew D. Back. 1997. “Face Recognition: A Convolutional Neural Network Approach.” *IEEE Transactions on Neural Networks*, Volume 8; Issue 1.
- [5] Graves, Alex. 2014. “Generating Sequences With Recurrent Neural Networks.” <http://arxiv.org/abs/1308.0850>
- [6] Lee JG, Jun S, Cho YW, Lee H, Kim GB, Seo JB, et al. Deep learning in medical imaging: general overview. *Korean J Ra- diol* 2017;18:570-584.
- [7] Erickson BJ, Korfiatis P, Akkus Z, Kline TL. Machine learning for medical imaging. *Radiographics* 2017;37:505-515.
- [8] Sermanet, Pierre, and Yann LeCun. 2011. “Traffic Sign Recognition with Multi Scale Networks.” Courant Institute of Mathematical Sciences, New York University.
- [9] The Brain Trauma Foundation. The American Association of Neurological Surgeons. The Joint Section on Neurotrauma and Critical Care. Computed tomography scan features. *J Neurotrauma*, 2000. 17(6-7): p. 597-627.
- [10] Bullock, M.R., et al., Evaluation of relevant computed tomographic scan findings. *Neurosurgery*, 2006. 58(3 Suppl. 2): p. 62.
- [11] A Simple, Fast and Fully Automated Approach for Midline Shift Measurement on Brain Computed Tomography. Huan-Chih Wang, Shih-Hao Ho, Furen Xiao, Jen-Hai Chou. 2.03.2017

- [12] S. Sergyan. Precision improvement of content- based image retrieval using dominant color histogram descriptor. In Recent Advances in Image, Audio and Signal Processing, 1st WSEAS Inter- national Conference on Image Processing and Pattern Recognition, pages 197–203, 2013
- [13] S. Le Cessie and J. Van Houwelingen. Ridge estimators in logistic regression. *Applied statistics*, pages 191–201, 1992.
- [14] C.-C. Liao, F. Xiao, J.-M. Wong, and I.-J. Chi- ang. A knowledge discovery approach to diagnosing intracranial hematomas on brain ct: recognition, measurement and classification. In *Medical Biometrics*, pages 73–82. Springer, 2007.